

Predicción de Abandono de Clientes

Integrantes: Javiera Olivares
Patricio Maldonado
Adriano Contreras

25 de mayo de 2026

Resumen ejecutivo

Este informe técnico detalla el desarrollo de un sistema de predicción para identificar clientes propensos al abandono (churn) y estimar su gasto mensual. El proyecto se basa en el análisis de un conjunto de datos histórico de clientes, aplicando técnicas de Machine Learning para abordar dos problemas clave en la gestión de relaciones con el cliente (CRM). Se realizó un análisis exploratorio de datos (EDA) para comprender la calidad y distribución de las variables, seguido de un riguroso proceso de preprocesamiento para limpiar y transformar los datos. Se entrenaron y evaluaron modelos de clasificación (Regresión Logística, Árbol de Decisión, SVM) para la predicción de abandono y modelos de regresión (Regresión Lineal, Árbol de Decisión) para la estimación del gasto. Finalmente, se optimizaron los hiperparámetros de los modelos seleccionados para mejorar su rendimiento, logrando identificar los modelos más robustos para cada tarea.

Marco Metodológico

La metodología empleada en este proyecto abarca desde la preparación de los datos hasta la selección y optimización de los modelos de Machine Learning. El objetivo principal fue construir modelos predictivos robustos y precisos para la identificación de abandono de clientes y la estimación de su gasto mensual.

Preprocesamiento de Datos

El proceso de preprocesamiento de datos fue crucial para asegurar la calidad y la idoneidad de los datos para el modelado. Las etapas clave incluyeron:

- Carga de Datos:** Se cargó el archivo `dataset_clientes.csv` que contiene información demográfica, financiera y de comportamiento de los clientes.
- Eliminación de Duplicados:** Se eliminaron registros duplicados basándose en la columna `id_cliente` para asegurar la unicidad de cada observación.
- Tratamiento de Valores Negativos:** Los valores negativos en variables financieras como `ingreso_mensual`, `gasto_mensual` y `deuda_total` fueron convertidos a NaN (valores nulos), asumiendo que representan datos erróneos o ausentes.
- Ingeniería de Características (Feature Engineering):** Se crearon nuevas variables para enriquecer el conjunto de datos:
`ratio_deuda`: Calculado como $\text{deuda_total} / (\text{ingreso_mensual} + 1)$ para capturar la

proporción de deuda en relación con los ingresos.

hora_sin y hora_cos : Transformaciones cíclicas de la variable

hora_registro para capturar patrones temporales sin imponer una relación lineal.

5. **Tratamiento de Valores Atípicos (Winsorization):** Se aplicó un Winsorizer para recortar los valores extremos de las columnas numéricas al percentil 5% inferior y 95% superior. Esto ayuda a mitigar el impacto de los valores atípicos en el rendimiento del modelo.

6. **Imputación de Valores Nulos:** Los valores nulos restantes fueron tratados mediante imputación:

Variables Numéricas: Se utilizó SimpleImputer con la estrategia de la media para rellenar los valores faltantes.

Variables Categóricas: Se utilizó SimpleImputer con la estrategia de la moda (valor más frecuente).

7. **Escalado de Características:** Las variables numéricas fueron escaladas utilizando StandardScaler para asegurar que todas las características contribuyan de manera equitativa al modelo, evitando que las variables con rangos de valores más grandes dominen el proceso de entrenamiento.

8. **Codificación de Variables Categóricas:** Las variables categóricas fueron transformadas utilizando OneHotEncoder con la opción drop="first" para evitar la multicolinealidad y handle_unknown="ignore" para manejar categorías no vistas durante el entrenamiento.

Modelos Base

Se seleccionaron y entrenaron varios modelos de Machine Learning como línea base para cada tarea:

Clasificación (Predicción de Abandono)

Para la predicción de abandono, se utilizaron los siguientes clasificadores:

Regresión Logística (LogisticRegression): Un modelo lineal interpretable que sirve como un buen punto de partida estadístico. Se configuró con max_iter=1000 , random_state=42 y class_weight="balanced" para manejar el desbalance de clases.

Árbol de Decisión (DecisionTreeClassifier): Un modelo no lineal que puede capturar relaciones complejas en los datos y es relativamente fácil de interpretar. Se configuró con

`random_state=42` y `class_weight="balanced"` .

Máquinas de Soporte Vectorial (SVC): Un modelo robusto en espacios de alta dimensión, capaz de encontrar un margen de separación óptimo. Se utilizó un kernel `rbf` , `probability=True` para obtener probabilidades, `random_state=42` y `class_weight="balanced"` .

Regresión (Predicción de Gasto Mensual)

Para la predicción del gasto mensual, se emplearon los siguientes regresores:

Regresión Lineal (LinearRegression): Un modelo lineal simple y altamente interpretable, utilizado como línea base.

Árbol de Decisión para Regresión (DecisionTreeRegressor): Capaz de capturar relaciones no lineales en el gasto. Se configuró con `random_state=42` .

Análisis Experimental

El análisis experimental se llevó a cabo sobre un conjunto de datos de clientes, donde el objetivo era predecir si un cliente abandonaría el servicio (`abandono`) y cuál sería su `gasto mensual` . El dataset original contenía 20,400 entradas y 22 columnas, con variables demográficas, de comportamiento y financieras. Tras el preprocesamiento, se obtuvo un conjunto de datos limpio y transformado, listo para el modelado.

Partición de Datos

Para la evaluación de los modelos, el conjunto de datos se dividió en conjuntos de entrenamiento y prueba. Se utilizó una proporción del 80% para entrenamiento y 20% para prueba (`test_size=0.2`). Para la tarea de clasificación, se aplicó `stratify=y_clf` para asegurar que la proporción de la clase objetivo (`abandono`) fuera la misma en ambos conjuntos, lo cual es crucial dado el desbalance de clases. Para la regresión, la división fue aleatoria.

Métricas de Evaluación

Clasificación: Se utilizaron Accuracy , Precision , Recall , F1-Score y ROC AUC . El F1-Score fue la métrica principal debido al desbalance de clases, ya que proporciona un equilibrio entre precisión y exhaustividad.

Regresión: Se utilizaron MAE (Error Absoluto Medio), MSE (Error Cuadrático Medio), RMSE (Raíz del Error Cuadrático Medio) y R^2 (Coeficiente de

Determinación). Un R^2 cercano a 1 indica un mejor ajuste del modelo.

Resultados y Comparación de Modelos

Clasificación (Predicción de Abandono)

Los resultados de los modelos base para la clasificación de abandono se muestran en la siguiente tabla:

Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
LogisticRegression	0.63325	0.531579	0.636421	0.579295	0.688275
DecisionTreeClassifier	0.56275	0.448210	0.441714	0.444938	0.542034
SVM	0.63025	0.528037	0.640832	0.578992	0.671646

Los modelos de Regresión Logística y SVM mostraron un rendimiento similar y superior al Árbol de Decisión en términos de F1-Score y ROC-AUC. La Regresión Logística obtuvo el mejor ROC-AUC, indicando una mejor capacidad para distinguir entre clases.

Regresión (Predicción de Gasto Mensual)

Los resultados de los modelos base para la regresión del gasto mensual se presentan a continuación:

Modelo	MAE	MSE	RMSE	R2
LinearRegression	120048.252519	2.249173e+10	149972.427559	-0.001907
DecisionTreeRegressor	174743.150314	4.760008e+10	218174.432497	-1.120373

Ambos modelos de regresión base mostraron un rendimiento pobre, con valores de R^2 negativos, lo que sugiere que no explican la varianza del gasto mensual mejor que un modelo que predice la media. Esto indica la necesidad de una optimización de hiperparámetros o la exploración de modelos más complejos.

Optimización de Hiperparámetros

La optimización de hiperparámetros se realizó para mejorar el rendimiento de los modelos base. Se utilizaron GridSearchCV para búsquedas exhaustivas en espacios de hiperparámetros pequeños y RandomizedSearchCV para espacios más grandes, especialmente para SVM. Para la validación cruzada, se empleó StratifiedkFold en clasificación para mantener la proporción de clases y KFold en regresión.

Clasificación

Regresión Logística: Se optimizó el hiperparámetro C (inverso de la fuerza de regularización) con una grilla de [0.01, 0.1, 1.0, 10.0, 100.0] . El mejor F1- Score (CV) fue de 0.688191.

Árbol de Decisión Clasificador: Se optimizaron max_depth (profundidad máxima del árbol) y min_samples_split (número mínimo de muestras requeridas para dividir un nodo) con grillas de [3, 5, 7, 10] y [2, 5, 10] respectivamente. El mejor F1-Score (CV) fue de 0.670545.

SVM: Se optimizaron C y gamma (coeficiente del kernel) utilizando RandomizedSearchCV debido al espacio de búsqueda más amplio. El mejor F1- Score (CV) fue de 0.671646.

Los resultados de los clasificadores optimizados en el conjunto de prueba fueron:

Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
LogisticRegression_Opt	0.63275	0.530987	0.637051	0.579204	0.688191
DecisionTreeClassifier_Opt	0.62700	0.524422	0.642722	0.577576	0.670545

Se observa que la optimización de hiperparámetros no produjo mejoras significativas en el F1-Score y ROC-AUC para la Regresión Logística y el Árbol de Decisión, lo que sugiere que los modelos base ya estaban cerca de su rendimiento óptimo con los hiperparámetros por defecto o que el espacio de búsqueda no fue lo suficientemente amplio.

Regresión

Regresión Lineal: No se realizó optimización de hiperparámetros ya que es un modelo lineal simple sin hiperparámetros relevantes para ajustar en este contexto.

Árbol de Regresión: Se optimizaron `max_depth` y `min_samples_split` con grillas de [3, 5, 7, 10, None] y [2, 5, 10] respectivamente. El mejor R^2 (CV) fue de -0.0007042137002895021.

Los resultados del `DecisionTreeRegressor` optimizado en el conjunto de prueba fueron:

Métrica	Valor
MAE	120066.560951
MSE	2.246473e+10
RMSE	149882.394912
R2	-0.000704

La optimización del Árbol de Regresión tampoco mostró una mejora sustancial, manteniendo un R^2 negativo. Esto refuerza la idea de que la predicción del gasto mensual es una tarea más compleja con este conjunto de datos o que los modelos lineales y basados en árboles simples no son adecuados para capturar las relaciones subyacentes.

Conclusiones

El proyecto ha permitido desarrollar un pipeline completo para la predicción de abandono de clientes y la estimación de su gasto mensual. Se ha demostrado la importancia de un preprocesamiento de datos exhaustivo, incluyendo el tratamiento de duplicados, valores negativos, atípicos, nulos, ingeniería de características, escalado y codificación. Los modelos de clasificación, especialmente la Regresión Logística y SVM, mostraron una capacidad razonable para predecir el abandono, con F1-Scores y ROC-AUCs que indican un rendimiento superior a la clasificación aleatoria. Sin embargo, la optimización de hiperparámetros no produjo mejoras significativas en estos modelos, sugiriendo que los hiperparámetros por defecto o el espacio de búsqueda inicial eran adecuados.

Por otro lado, los modelos de regresión (Regresión Lineal y Árbol de Decisión) tuvieron un rendimiento muy deficiente en la predicción del gasto mensual, con R^2 negativos incluso después de la optimización. Esto sugiere que las variables disponibles en el dataset no son suficientes para

modelar el gasto mensual de manera efectiva con estos tipos de modelos, o que la relación entre las características y el gasto es altamente no lineal y compleja.

Dificultades y Alternativas Evaluadas

Una dificultad clave fue el desbalance de clases en la tarea de clasificación, lo cual se abordó utilizando `class_weight="balanced"` en los modelos y seleccionando el F1- Score como métrica principal. Otra dificultad fue la presencia de valores nulos y atípicos, que se manejaron con imputación y winsorización. La baja capacidad predictiva de los modelos de regresión fue una limitación importante, lo que llevó a la conclusión de que se necesitan enfoques más avanzados.

Recomendaciones Futuras

1. **Exploración de Modelos Avanzados:** Para la predicción del gasto mensual, se recomienda explorar modelos más complejos como Gradient Boosting Machines (XGBoost, LightGBM) o redes neuronales, que son capaces de capturar relaciones no lineales y complejas de manera más efectiva.
2. **Ingeniería de Características Adicional:** Investigar la creación de nuevas características que puedan tener una mayor correlación con el gasto mensual, como el historial de transacciones detallado, la interacción con promociones, o el uso de servicios específicos.
3. **Análisis de Importancia de Características:** Realizar un análisis de importancia de características para identificar cuáles son las variables más influyentes en la predicción del gasto y el abandono. Esto podría guiar futuras recolecciones de datos o la creación de nuevas características.
4. **Recolección de Datos Adicionales:** Si es posible, considerar la recolección de datos adicionales que puedan enriquecer el perfil del cliente y su comportamiento de gasto.
5. **Optimización de Hiperparámetros más Exhaustiva:** Para los modelos de clasificación, aunque la mejora fue limitada, se podría explorar un espacio de hiperparámetros más amplio o utilizar técnicas de optimización bayesiana para encontrar configuraciones óptimas.